

Probabilidades e Estatística

Variáveis Aleatórias

Prof. Caldeira Duarte e Prof.^a Anabela Pereira

Actualizado pelo Prof. António Sardinha (Fevereiro de 2013)

Actualizado pela Prof.^a Paula Pereira (Fevereiro de 2017)

Departamento de Matemática



1 VARIÁVEIS ALEATÓRIAS

Em muitas experiências aleatórias os elementos do espaço de resultados, Ω , são números reais ou conjuntos ordenados de números reais. Assim acontece com o registo de temperaturas, da pluviosidade, no lançamento de dois dados, etc. Mas já o resultado do lançamento de uma moeda ao ar não é um resultado numérico.

Quando Ω não é um conjunto numérico atribui-se muitas vezes a cada elemento ω do espaço de resultados, um número real, atribuição essa que pode ser meramente convencional.

Exemplo 1.1. No lançamento de uma moeda ao ar, o espaço de resultados é o conjunto $\Omega = \{\text{Cara}, \text{Coroa}\}$; é usual neste caso fazer a correspondência

ω	$X(\omega)$
Cara	1
Coroa	0

Para o mesmo espaço de resultados Ω , é possível estabelecer diferentes correspondências, consoante os objectivos em estudo. ■

Exemplo 1.2. Considere-se uma população de empresas das quais se escolhe uma ao acaso. $\Omega = \{\omega_1, \omega_2, \dots, \omega_m\}$ será o espaço de resultados e m o número total de empresas.

Podemos definir várias correspondências:

$\omega \rightarrow X(\omega)$, sendo $X(\omega)$ o número de empregados da empresa ω ,

$\omega \rightarrow Y(\omega)$, sendo $Y(\omega)$ o volume de vendas da empresa ω ,

ou quaisquer outras, conforme o objectivo em estudo. ■

Supondo agora que só estamos interessados no estudo de uma característica dos elementos de Ω , associemos a cada elemento $\omega \in \Omega$ um número real $X(\omega)$. Estamos assim a definir uma função $X : \Omega \rightarrow \mathbb{R}$. Sendo A um acontecimento, chama-se imagem de A por X , e representa-se por $X(A)$, ao conjunto dos valores que X assume para os elementos ω de A , isto é,

$$X(A) = \{X(\omega) : \omega \in A\}.$$

Por outro lado, a cada subconjunto $E \subset \mathbb{R}$, pode fazer-se corresponder o subconjunto $X^{-1}(E)$ formado por todos os elementos $\omega \in \Omega$ tais que $X(\omega) \in E$,

$$X^{-1}(E) = \{\omega : X(\omega) \in E\}.$$

A este conjunto $X^{-1}(E)$ chama-se a imagem inversa de E por X .

Exemplo 1.3. No lançamento de dois dados interessa somente, num dado jogo, a soma dos pontos obtidos. Neste caso, o espaço de resultados é o conjunto

$$\Omega = \{(i, j) : i, j = 1, 2, 3, 4, 5, 6\};$$

defina-se a aplicação

$$X(i, j) = i + j.$$

Sendo $A = \{(1, 1), (1, 2), (2, 1)\}$, a imagem de A por X é $X(A) = \{2, 3\}$; para o acontecimento $B = \{(4, 5), (5, 4), (5, 5), (6, 6)\}$, a imagem de B por X é $X(B) = \{9, 10, 12\}$.

Para o subconjunto real $E_1 = \{2, 3\}$, a imagem inversa de E_1 por X é o acontecimento $X^{-1}(E_1) = \{(1, 1), (1, 2), (2, 1)\}$; se $E_2 = [2, +\infty[$, $X^{-1}(E_2) = \Omega$ e se $E_3 =]-\infty, \frac{1}{2}]$, $X^{-1}(E_3) = \emptyset$. ■

Estamos agora em condições de perceber a definição de variável aleatória.

Definição 1.4. Uma variável aleatória (v.a.), X , é uma função com domínio no conjunto Ω dos acontecimentos elementares e contradomínio no conjunto \mathbb{R} , cuja imagem inversa de qualquer intervalo $E \subset \mathbb{R}$ é um acontecimento aleatório.

Observação 1.5. Uma variável aleatória é uma função e não uma variável no sentido em que é habitualmente empregue em Matemática!

1.1 Funções de Distribuição

Considere-se agora uma variável aleatória X , um intervalo real $E =]-\infty, x]$ e a respectiva imagem inversa $X^{-1}(E)$. Pela definição de variável aleatória existe sempre

$$P(X \leq x) = P[X^{-1}(E)].$$

Como $P(X \leq x)$ depende de x , a igualdade $F(x) = P(X \leq x)$ define uma função real de variável real.

Definição 1.6. A função $F(x)$ definida por $F(x) = P(X \leq x)$ chama-se a **Função de Distribuição** da variável aleatória X .

Vamos agora enunciar algumas das propriedades elementares mais importantes das funções de distribuição. As demonstrações destas propriedades podem ser vistas em [3]. Tem-se então que, se $F(x)$ é uma função de distribuição,

Proposição 1.7. $0 \leq F(x) \leq 1$.

Proposição 1.8. $F(x)$ é uma função não decrescente.

Proposição 1.9. $F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0$ e $F(+\infty) = \lim_{x \rightarrow +\infty} F(x) = 1$.

Proposição 1.10. $P(a < X \leq b) = F(b) - F(a)$.

Proposição 1.11. $F(x)$ é contínua à direita.

Proposição 1.12. $P(X = a) = F(a) - \lim_{x \rightarrow a^-} F(x)$.

Desta proposição pode concluir-se que, se a função de distribuição é contínua para todo o $x \in \mathbb{R}$, tem-se $P(X = x) = 0$, isto é, todos os pontos reais têm probabilidade zero. Mas atenção: isto não significa forçosamente que os acontecimentos $(X = x)$ sejam impossíveis.

Proposição 1.13. O conjunto de pontos de descontinuidade de qualquer função de distribuição, se não for vazio, é finito ou infinito numerável.

Iremos agora tratar fundamentalmente de dois tipos de variáveis aleatórias, as do tipo discreto e as do tipo contínuo.

1.2 Variáveis Aleatórias Discretas

Definição 1.14. Seja X uma variável aleatória e D o conjunto

$$D = \{a : P(X = a) > 0\}$$

(conjunto dos pontos de descontinuidade da função de distribuição). A variável aleatória X diz-se do tipo **discreto** quando $P(X \in D) = 1$.

Quando a variável aleatória é discreta existe um conjunto finito ou infinito numerável,

$$D = \{a_1, a_2, \dots, a_n, \dots\},$$

tal que,

$$P(X \in D) = \sum_i P(X = a_i) = 1 \quad \text{e} \quad P(X = a_i) > 0, i = 1, 2, \dots$$

Definição 1.15. Seja D o conjunto definido anteriormente. A função,

$$f(x) = \begin{cases} P(X = x) > 0 & \text{se } x \in D \\ 0 & \text{se } x \notin D \end{cases}$$

chama-se **função de probabilidade** da variável aleatória X e verifica as seguintes propriedades:

$$f(x) \geq 0;$$

$$\sum_x f(x) dx = 1.$$

A função de distribuição de uma variável aleatória discreta pode exprimir-se facilmente em termos da respectiva função de probabilidade:

$$F(x) = P(X \leq x) = \sum_{x_i \leq x} f(x_i) = \sum_{x_i \leq x} P(X = x_i).$$

Exemplo 1.16. Seja X a variável aleatória que representa o número de caras saídas no lançamento de 3 moedas equilibradas. O quadro seguinte apresenta a função de probabilidade (ver Figura 1.1) desta variável:

x	0	1	2	3
$f(x)$	1/8	3/8	3/8	1/8

Como $F(x) = P(X \leq x)$ então a função de distribuição (ver Figura 1.1) será:

$$\text{se } x < 0 \quad \Rightarrow \quad F(x) = P(X \leq x) = P(\emptyset) = 0$$

$$\text{se } 0 \leq x < 1 \quad \Rightarrow \quad F(x) = P(X = 0) = 1/8 = 0.125$$

$$\text{se } 1 \leq x < 2 \quad \Rightarrow \quad F(x) = P(X = 0) + P(X = 1) = 1/8 + 3/8 = 0.5$$

$$\text{se } 2 \leq x < 3 \quad \Rightarrow \quad F(x) = P(X = 0) + P(X = 1) + P(X = 2) = 1/8 + 3/8 + 3/8 = 0.875$$

$$\text{se } x \geq 3 \quad \Rightarrow \quad F(x) = P(X = 0) + P(X = 1) + P(X = 2) + P(X = 3) = P(\Omega) = 1$$

Resumindo,

$$F(x) = \begin{cases} 0 & , \quad x < 0 \\ 0.125 & , \quad 0 \leq x < 1 \\ 0.5 & , \quad 1 \leq x < 2 \\ 0.875 & , \quad 2 \leq x < 3 \\ 1 & , \quad x \geq 3 \end{cases} .$$




Figura 1.1: Função de probabilidade e Função de distribuição da v.a. discreta do exemplo 1.16

■

1.3 Variáveis Aleatórias Contínuas

Definição 1.17. Seja X uma variável aleatória e $F(x)$ a respectiva função de distribuição; se,

$$D = \{a : P(X = a) > 0\} = \emptyset,$$

resulta da proposição 1.12 que $F(x)$ não apresenta descontinuidades. Se, além disso, existe uma função não negativa, $f(x) \geq 0$, tal que para todo o número real x se verifica a relação,

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(u) du,$$

então a variável aleatória X diz-se **contínua**.

Definição 1.18. A função não negativa, $f(x)$, introduzida na definição anterior, chama-se **função de densidade de probabilidade** ou simplesmente **função de densidade**.

Exemplo 1.19. Suponha que tem uma variável aleatória contínua, X , com a seguinte função de distribuição (ver Figura 1.2):

$$F(x) = \begin{cases} 0 & \text{se } x \leq 1 \\ \frac{x-1}{2} & \text{se } 1 < x < 3 \\ 1 & \text{se } x \geq 3 \end{cases} .$$

A derivada $F'(x)$ existe em todos os pontos da recta real excepto em $x = 1$ e $x = 3$. Então $f(x)$, a função de densidade de probabilidade é igual à derivada da função de distribuição

em todos os pontos onde exista (ver Figura 1.2), e convencionam-se que é nula nos restantes, isto é

$$f(x) = \begin{cases} F'(x) & , \text{ nos pontos onde existe derivada} \\ 0 & , \text{ nos outros pontos} \end{cases}$$

então, neste caso, tem-se

$$f(x) = \begin{cases} \frac{1}{2} & \text{se } 1 < x < 3 \\ 0 & \text{se } x \leq 1 \vee x \geq 3 \end{cases} .$$




Figura 1.2: Função de densidade de probabilidade e Função de distribuição da v.a. contínua do exemplo 1.19

■

Exemplo 1.20. Suponha que X é uma variável aleatória contínua com a seguinte função densidade de probabilidade

$$f(x) = \begin{cases} 1+x & \text{se } -1 \leq x < 0 \\ 1-x & \text{se } 0 \leq x \leq 1 \\ 0 & \text{se } x < -1 \vee x > 1 \end{cases} .$$

Como $F(x) = P(X \leq x) = \int_{-\infty}^x f(u)du$ então a função de distribuição (ver Figura 1.3) será:

$$\text{se } x < -1 \quad \Rightarrow \quad F(x) = \int_{-\infty}^x 0du = 0$$

$$\text{se } -1 \leq x < 0 \quad \Rightarrow \quad F(x) = \int_{-\infty}^{-1} 0du + \int_{-1}^x (1+u)du = \frac{x^2}{2} + x + \frac{1}{2}$$

$$\text{se } 0 \leq x \leq 1 \quad \Rightarrow \quad F(x) = \int_{-\infty}^{-1} 0du + \int_{-1}^0 (1+u)du + \int_0^x (1-u)du = -\frac{x^2}{2} + x + \frac{1}{2}$$

$$\text{se } x > 1 \quad \Rightarrow \quad F(x) = \int_{-\infty}^{-1} 0du + \int_{-1}^0 (1+u)du + \int_0^1 (1-u)du + \int_1^x 0du = 1$$

Resumindo,

$$F(x) = \begin{cases} 0 & , \quad x < -1 \\ \frac{x^2}{2} + x + \frac{1}{2} & , \quad -1 \leq x < 0 \\ -\frac{x^2}{2} + x + \frac{1}{2} & , \quad 0 \leq x \leq 1 \\ 1 & , \quad x > 1 \end{cases}.$$




Figura 1.3: Função de densidade de probabilidade e Função de distribuição da v.a. contínua do exemplo 1.20

■

Da definição de função de distribuição e da sua relação com a função de densidade de probabilidade, têm-se as seguintes propriedades:

$$f(x) \geq 0;$$

$$\int_{-\infty}^{+\infty} f(x)dx = 1;$$

$$\int_a^b f(x)dx = F(b) - F(a) = P(a < X < b).$$

Observação 1.21. Repare-se que $P(a < X < b)$ pode ser interpretada geometricamente como uma área, visto que é calculada através de um integral definido de uma função não negativa (ver Figura 1.4).




Figura 1.4: $P(a < X < b) = \int_a^b f(x)dx$

Observação 1.22. Devido à continuidade da função de distribuição,

$$P(X = a) = P(X = b) = 0,$$

e pode escrever-se

$$P(a < X \leq b) = P(a \leq X < b) = P(a \leq X \leq b) = P(a < X < b), \quad b > a.$$

1.4 Valores Esperados e Parâmetros

De acordo com [3], o conceito de valor esperado teve a sua origem nos jogos de acaso e foi, segundo se diz, introduzido por Huygens.

Exemplo 1.23. Considere-se um sorteio em que foram vendidos 10000 bilhetes e cujos prémios, em euros, são:

- 1) um 1º prémio de 500000;
- 2) um 2º prémio de 60000;
- 3) três 3ºs prémios de 30000;
- 4) dez 4ºs prémios de 10000.

Se fizermos a soma dos produtos dos valores dos prémios que se podem ganhar pelas respectivas probabilidades,

$$500000 \left(\frac{1}{10000} \right) + 60000 \left(\frac{1}{10000} \right) + 30000 \left(\frac{3}{10000} \right) + 10000 \left(\frac{10}{10000} \right) = 75 \text{ euros}$$

obtemos aquilo que se chama valor esperado ou esperança matemática do comprador de um bilhete.

Suponhamos que uma pessoa compra sistematicamente um bilhete de uma lotaria deste tipo. Ao fim n repetições, o ganho total é dado por

$$500000.s_n(1) + 60000.s_n(2) + 30000.s_n(3) + 10000.s_n(4),$$

sendo $s_n(i)$ o número de vezes que saiu o i -ésimo prémio, $i = 1, 2, 3, 4$.

O ganho médio foi

$$500000.[s_n(1)/n] + 60000.[s_n(2)/n] + 30000.[s_n(3)/n] + 10000.[s_n(4)/n].$$

A interpretação frequencista do conceito de probabilidade sugere que, para n grande, as frequências relativas são praticamente iguais à probabilidade. Isto significa que ao fim de um grande número de jogadas o ganho médio será aproximadamente igual ao valor da chamada esperança matemática. É por isso que se diz que um jogo é equitativo quando o que se paga para nele participar é igual à esperança matemática do jogador: após um grande número de partidas, o ganho médio por partida não se afastará muito do preço pago para participar em cada partida. ■

Com qualquer distribuição de uma variável aleatória estão sempre associados certos números chamados os **parâmetros da distribuição**, que desempenham um relevante papel na Estatística Matemática. Duas importantes famílias de parâmetros de uma distribuição são: os **momentos** e os **parâmetros de ordem**; iremos, no entanto, apenas abordar os primeiros.

Definição 1.24. O **momento de ordem k em relação à origem** ou momento ordinário de ordem k - k inteiro positivo - de uma variável aleatória é o valor esperado da função $G(X) = X^k$, isto é,

$$\mu_k = E[X^k].$$

Se a variável aleatória for discreta,

$$E[X^k] = \sum_i x_i^k f(x_i);$$

no caso de ser contínua,

$$E[X^k] = \int_{-\infty}^{+\infty} x^k f(x) dx.$$

Definição 1.25. O momento de ordem 1 em relação à origem de uma variável aleatória chama-se **esperança matemática, média** ou **valor esperado** e representa-se por μ ou $E[X]$.

Se a variável aleatória for discreta, o valor esperado é

$$\mu = E[X] = \sum_i x_i f(x_i);$$

no caso de ser contínua é

$$\mu = E[X] = \int_{-\infty}^{+\infty} x f(x) dx.$$

Definição 1.26. O **momento de ordem k em relação à média** ou **momento central de ordem k** - k inteiro positivo - de uma variável aleatória é o valor esperado da função $G(X) = (X - \mu)^k$, isto é,

$$E[(X - \mu)^k].$$

Se a variável aleatória for discreta,

$$E[(X - \mu)^k] = \sum_i (x_i - \mu)^k f(x_i);$$

no caso de ser contínua,

$$E[(X - \mu)^k] = \int_{-\infty}^{+\infty} (x - \mu)^k f(x) dx.$$

Definição 1.27. O momento central de 2ª ordem de uma variável aleatória X , é chamado **variância** de X , e representa-se habitualmente por $V[X]$ ou σ^2 .

Se a variável aleatória for discreta, a variância é

$$\sigma^2 = E[(X - \mu)^2] = \sum_i (x_i - \mu)^2 f(x_i);$$

no caso de ser contínua é

$$\sigma^2 = E[(X - \mu)^2] = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx.$$

Definição 1.28. A raiz quadrada positiva da variância de uma variável aleatória X , chama-se o **desvio padrão** e representa-se habitualmente por σ .

Os parâmetros σ^2 e σ são medidas de dispersão da variável aleatória em torno do seu valor esperado. Quanto mais concentrada for a distribuição, tanto menor será o valor de σ^2 ou σ . A vantagem de σ em relação a σ^2 é que vem expressa na mesma unidade de medida da variável aleatória.

A seguir apresentam-se algumas propriedades do Valor Esperado e da Variância cuja demonstração se deixa como exercício ao aluno.

Proposição 1.29. Se X é uma variável aleatória constante, isto é, se $X \equiv a$, então

$$E[X] = a.$$

Proposição 1.30. Se X é uma variável aleatória e a e b são constantes reais

$$E[aX + b] = aE[X] + b.$$

Proposição 1.31. Seja X uma variável aleatória e $G(X)$ e $H(X)$ funções de X ; então

$$E[G(X) + H(X)] = E[G(X)] + E[H(X)].$$

Proposição 1.32. Se X é uma variável aleatória,

$$V[X] = E[X^2] - E^2[X].$$

Demonstração.

$$\begin{aligned} V[X] &= E[(X - \mu)^2] = E[X^2 - 2\mu X + \mu^2] = \\ &= E[X^2] - 2\mu \underbrace{E[X]}_{\mu} + \mu^2 = E[X^2] - 2\mu^2 + \mu^2 = \\ &= E[X^2] - \mu^2 = E[X^2] - (E[X])^2 = E[X^2] - E^2[X] \end{aligned}$$

□

Proposição 1.33. Se X é uma variável aleatória,

$$V[X] \geq 0.$$

Proposição 1.34. Se X é uma variável aleatória constante, isto é, se $X \equiv a$, então

$$V[X] = 0.$$

Proposição 1.35. Se X é uma variável aleatória e a e b são constantes reais

$$V[aX + b] = a^2 V[X].$$

1.5 Adenda

Se pretendermos analisar e relacionar duas variáveis aleatórias, X e Y , há parâmetros que caracterizam as ligações existentes entre ambas.

1.6 Covariância

A covariância é uma medida da distribuição conjunta dos valores dos desvios de X e Y em relação às respectivas médias; este parâmetro permite descrever o tipo de relação linear (positiva ou negativa) que existe (ou não) entre as variáveis unidimensionais X e Y .

Definição 1.36. A **covariância** entre X e Y [$cov(X, Y)$ ou $\sigma_{X,Y}$] define-se como:

$$cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = \sigma_{X,Y}.$$

Algumas das propriedades da covariância são dadas em seguida.

Proposição 1.37. Sejam X e Y duas variáveis aleatórias, então a sua covariância pode calcular-se do seguinte modo,

$$cov(X, Y) = E[XY] - E[X]E[Y].$$

Demonstração.

$$\begin{aligned} cov(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] = \\ &= E[XY - \mu_X Y - \mu_Y X + \mu_X \mu_Y] = \\ &= E[XY] - \underbrace{\mu_X E[Y]}_{\mu_Y} - \underbrace{\mu_Y E[X]}_{\mu_X} + \mu_X \mu_Y = \\ &= E[XY] - E[X]E[Y] \end{aligned}$$

□

Proposição 1.38. Se X e Y são variável aleatória independentes então,

$$E[XY] = E[X]E[Y] \text{ e } cov(X, Y) = 0.$$

O recíproco deste último resultado pode não ser verdadeiro, isto é sendo $cov(X, Y) = 0$ não se pode inferir que X e Y sejam independentes, somente que não existe uma relação linear entre as variáveis. Pode contudo existir uma ligação não linear entre X e Y .

Proposição 1.39. Sejam X e Y duas variáveis aleatórias,

- $E[X \pm Y] = E[X] \pm E[Y]$;
- $V[X \pm Y] = V[X] + V[Y] \pm 2cov(X, Y)$;
- Se X e Y são independentes, então $V[X \pm Y] = V[X] + V[Y]$.

Referências

- [1] FISZ, M., *Probability Theory and Mathematical Statistics*, Jonh Wiley & Sons, Inc., New York, 1963.
- [2] GUIMARÃES, R.C. e CABRAL, J.A.S., *Estatística*, McGraw-Hill de Portugal, Lisboa, 1997.
- [3] MURTEIRA, B.J.F., *Probabilidades e Estatística*, McGraw-Hill de Portugal, Lisboa, 1979.
- [4] SPIEGEL, M.R., *Probabilidade e Estatística*, Coleção Schaum, McGraw-Hill do Brasil, São Paulo, 1978
- [5] OLIVEIRA, J.T., *Probabilidades e Estatística*, vol. I, Escolar Editora, Lisboa, 1967.
- [6] MELLO, F., *Introdução aos Métodos Estatísticos*, vol. I e II, Cadernos do Instituto de Orientação Profissional, Lisboa, 1973.
- [7] MONTGOMERY, D.; RUNGER, G., *Applied Statistics and Probability for Engineers*, Jonh Wiley & Sons, Inc., New York, 2003.